

Journal de stage

ESPRIT École d'Ingénieurs — Stage Ingénieur — Année universitaire 25/26

Informations générales

Nom et prénom de l'étudiant	Ghassen Bousselem
Niveau / Année	4ème année → 5ème année
Organisme d'accueil	EY — Digital & Emerging Technologies
Période de stage	du 22/06/2026 au 04/09/2026 (11 semaines)
Durée	11 semaines (55 jours ouvrés)
Intitulé de la mission	Extraction automatique de données d'actes d'état civil par modèles vision-langage et intégration au registre civil numérique OpenCRVS

Note : la version officielle du journal doit être complétée puis signée et tamponnée par l'encadrant de l'organisme d'accueil avant d'être numérisée. Ce document reprend le détail des travaux menés jour par jour et sert de support à cette rédaction.

Journal des activités

Date	Tâches réalisées
22/06/2026 lun	Accueil, présentation de l'équipe et du cadre de la mission. Mise en place du poste de travail et des accès.
23/06/2026 mar	Cadrage du sujet : numérisation des actes d'état civil africains et alimentation d'un registre civil numérique.
24/06/2026 mer	Étude du domaine : registres d'état civil, structure d'un acte de naissance, enjeux d'identité légale.
25/06/2026 jeu	État de l'art OCR : moteurs classiques (Tesseract) face aux modèles vision-langage (VLM) sur documents dégradés.
26/06/2026 ven	Découverte d'OpenCRVS : architecture, rôle des microservices, notion de déclaration et cycle de vie d'un dossier.
29/06/2026 lun	Collecte d'un corpus d'actes réels couvrant plusieurs pays africains ; inventaire des formats rencontrés.
30/06/2026 mar	Analyse comparée des mises en page : actes tapés, copies intégrales, extraits traduits, registres manuscrits.
01/07/2026 mer	Définition d'un schéma de champs commun (enfant, parents, dates, lieux) et des variantes par pays.
02/07/2026 jeu	Premiers essais d'extraction avec Tesseract : mesure des limites sur scans dégradés et documents multilingues.
03/07/2026 ven	Essais comparatifs avec un modèle vision-langage ; arbitrage en faveur d'une approche VLM.
06/07/2026 lun	Conception de l'architecture du pipeline : prétraitement, localisation, extraction, validation, score.
07/07/2026 mar	Implémentation du prétraitement d'image : redressement, mise à l'échelle, binarisation, variantes.
08/07/2026 mer	Développement de l'extraction VLM et du format de rapport structuré par document (report.json).
09/07/2026 jeu	Première version fonctionnelle de bout en bout ; mise en place du dépôt Git et de l'application web de dépôt.
10/07/2026 ven	Optimisation des performances : traitement des recadrages par lots parallèles, réduction de ~10 min à ~50 s par acte.
13/07/2026 lun	Étude de l'API OpenCRVS Event Notification ; conception du mapping report.json vers une déclaration V2.
14/07/2026 mar	Développement du module d'export et des tests associés ; premières déclarations pré-remplies transmises.
15/07/2026 mer	Déploiement d'une instance OpenCRVS complète en local (WSL, Docker, 14 microservices) pour valider l'intégration.
16/07/2026 jeu	Fiabilisation du démarrage : une tâche planifiée par service, scripts idempotents, script de lancement unique.
17/07/2026 ven	Bouton « envoyer vers OpenCRVS » dans l'application web ; rédaction du guide d'exploitation de la plateforme.

Date	Tâches réalisées
20/07/2026 lun	Extension de la couverture pays : ajout et vérification de packs de champs supplémentaires.
21/07/2026 mar	Table d'alias entre vocabulaires pays et identifiants de champs OpenCRVS (un même champ nommé différemment).
22/07/2026 mer	Gestion des cas dégradés : bascule automatique vers une localisation par le modèle quand le gabarit ne colle pas.
23/07/2026 jeu	Mise en place du seuil de confiance et du signalement « à vérifier » pour les valeurs incertaines.
24/07/2026 ven	Tests de robustesse, correction des anomalies détectées, revue de code et documentation technique.
27/07/2026 lun	Conception du protocole d'évaluation : indicateurs, périmètre, choix des documents représentatifs.
28/07/2026 mar	Développement du harnais d'évaluation par lot et export des résultats détaillés par document.
29/07/2026 mer	Ajout des indicateurs de précision, rappel et F1 ; analyse de la répartition des scores de confiance.
30/07/2026 jeu	Traitement du lot d'échantillons et analyse des écarts ; exclusion motivée des actes manuscrits.
31/07/2026 ven	Rédaction des notes de synthèse à destination de l'encadrante et présentation des premiers résultats.
03/08/2026 lun	Approfondissement de la littérature d'évaluation des VLM sur documents (DocVQA, SROIE, CORD, OmniDocBench).
04/08/2026 mar	Étude des métriques d'extraction : ANLS, taux d'erreur caractère et mot, F1 par champ, mesure des hallucinations.
05/08/2026 mer	Analyse critique des métriques de génération (BLEU, ROUGE) et de leur inadéquation à l'extraction structurée.
06/08/2026 jeu	Traitement des échantillons restants et consolidation du corpus d'évaluation.
07/08/2026 ven	Analyse des erreurs par pays ; identification des configurations les plus difficiles.
10/08/2026 lun	Étude du toolkit de formulaires V2 d'OpenCRVS : types de champs, valeurs calculées, conditions d'affichage.
11/08/2026 mar	Analyse du patron d'intégration existant (lecteur d'identité MOSIP) comme modèle pour une intégration native.
12/08/2026 mer	Conception de l'intégration dans le formulaire : dépôt du scan et pré-remplissage sans quitter OpenCRVS.
13/08/2026 jeu	Étude du stockage documentaire d'OpenCRVS (MinIO) et du parcours d'un fichier téléversé.
14/08/2026 ven	Spécification des points d'entrée nécessaires côté service OCR et validation de la faisabilité technique.
17/08/2026 lun	Développement des points d'entrée d'analyse destinés au formulaire OpenCRVS.

Date	Tâches réalisées
18/08/2026 mar	Mise au point de la lecture des pièces déposées depuis le stockage documentaire de la plateforme.
19/08/2026 mer	Enrichissement du mapping : nationalités, résolution du lieu de naissance, pièce jointe du scan d'origine.
20/08/2026 jeu	Renforcement des tests automatisés du module d'export et correction des cas limites identifiés.
21/08/2026 ven	Amélioration de la robustesse de la plateforme locale : diagnostic automatique au démarrage.
24/08/2026 lun	Développement du panneau de numérisation intégré à la page de déclaration OpenCRVS.
25/08/2026 mar	Câblage du pré-remplissage sur l'ensemble des pages du formulaire (enfant, parents, déclarant).
26/08/2026 mer	Diagnostic et correction du mécanisme de propagation des valeurs vers les champs du formulaire.
27/08/2026 jeu	Amélioration de l'extraction des noms et des nationalités à partir des cas réels rencontrés.
28/08/2026 ven	Réduction des fenêtres ouvertes au démarrage de la plateforme ; simplification de l'exploitation quotidienne.
31/08/2026 lun	Constitution d'un jeu de référence transcrit pour la mesure de justesse de l'extraction.
01/09/2026 mar	Implémentation des métriques ANLS, taux d'erreur caractère et mot, F1 par champ et taux d'hallucination.
02/09/2026 mer	Analyse des résultats ; identification d'un défaut réel sur l'ordre des noms dans certaines conventions.
03/09/2026 jeu	Rédaction du rapport d'évaluation et de la documentation technique du projet.
04/09/2026 ven	Bilan de stage avec l'encadrante, restitution des livrables et préparation du rapport final.

Signature de l'étudiant	Cachet et signature de l'encadrant