

République Tunisienne

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

ESPRIT — École Supérieure Privée d'Ingénierie et de Technologies

RAPPORT DE STAGE INGÉNIEUR

Extraction automatique de données d'actes d'état civil par modèles vision-langage

Conception d'un pipeline OCR multi-pays et intégration au registre civil numérique
OpenCRVS

Réalisé par :
Ghassen Bousselem

Organisme d'accueil :
à compléter

Encadrant entreprise :
à compléter

Encadrant académique :
à compléter

Période : du 22 juin 2026 au 4 septembre 2026

Année universitaire 2025 / 2026

Remerciements

Au terme de ce stage, je tiens à exprimer ma gratitude à celles et ceux qui ont rendu ce travail possible.

Je remercie en premier lieu à compléter : nom de l'encadrant entreprise, mon encadrant au sein de à compléter : nom de l'organisme, pour la confiance accordée dès les premiers jours, pour la liberté laissée dans les choix techniques et pour la qualité des retours qui ont orienté ce projet aux moments décisifs. Les orientations données sur l'intégration au registre civil ont transformé un prototype d'extraction en un outil réellement utilisable par un officier d'état civil.

Je remercie également à compléter : nom de l'encadrant académique, mon encadrant académique à ESPRIT, pour son accompagnement méthodologique et pour la rigueur exigée dans la démarche d'évaluation, laquelle constitue aujourd'hui l'une des contributions les plus solides de ce travail.

Mes remerciements vont aussi à l'ensemble de l'équipe de à compléter : nom de l'équipe pour son accueil, sa disponibilité et les échanges techniques qui ont nourri ma réflexion tout au long de ces onze semaines.

Enfin, je remercie le corps professoral et l'administration d'ESPRIT pour la formation dispensée, ainsi que ma famille pour son soutien constant.

Avant remise

Les mentions signalées en rouge dans ce document doivent être renseignées : elles concernent des informations propres à l'organisme d'accueil et aux personnes qui ont encadré ce stage, qui ne peuvent être ni supposées ni reconstituées. Elles apparaissent sur la page de garde, dans les remerciements, dans la présentation de l'organisme et sur l'organigramme.

Résumé

Dans de nombreux pays africains, une part importante des actes d'état civil n'existe que sous forme papier. Leur numérisation vers un registre civil électronique se heurte à un obstacle pratique : la ressaisie manuelle, longue, coûteuse et source d'erreurs.

Ce stage a consisté à concevoir et réaliser une chaîne de traitement capable de lire un acte de naissance scanné, d'en extraire les champs structurés à l'aide d'un modèle vision-langage, puis d'en pré-remplir une déclaration dans OPENCRVS, le registre civil numérique open source utilisé par plusieurs États. La chaîne couvre vingt-sept pays, traite un document en quarante à quatre-vingt-dix secondes, et s'intègre à OPENCRVS par deux voies complémentaires : son interface de notification d'événements, et un panneau de numérisation ajouté directement au formulaire de déclaration.

Un principe de conception traverse l'ensemble du système : préférer l'aveu d'incertitude à l'affirmation fausse. Chaque valeur porte un score de confiance, les valeurs douteuses sont signalées plutôt que présentées comme sûres, et aucune information n'est déduite lorsque le document ne la contient pas.

L'évaluation, menée sur un jeu de référence transcrit couvrant neuf actes et soixante-neuf champs, mesure une similarité ANLS de 0,967, un score F1 en correspondance exacte de 0,926 et un taux d'hallucination nul. Elle a également mis en évidence des défauts réels — une erreur de lecture d'année, des inversions systématiques entre prénom et nom dans certaines conventions nationales — qui sont documentés plutôt que passés sous silence.

Mots-clés : extraction d'information documentaire, modèles vision-langage, reconnaissance optique de caractères, état civil, identité légale, OPENCRVS, évaluation, ANLS.

Abstract

In many African countries, a large share of civil-status records exists only on paper. Digitising them into an electronic civil registry runs into a practical obstacle: manual re-entry is slow, expensive and error-prone.

This internship covered the design and implementation of a processing chain that reads a scanned birth certificate, extracts its structured fields using a vision-language model, and pre-fills a declaration in OPENCRVS, the open-source civil registry used by several governments. The chain covers twenty-seven countries, processes a document in forty to ninety seconds, and integrates with OPENCRVS through two complementary paths: its event notification interface, and a scanning panel added directly to the declaration form.

One design principle runs through the system: prefer admitting uncertainty over asserting something false. Every value carries a confidence score, doubtful values are flagged rather than presented as reliable, and nothing is inferred when the document does not contain it.

Evaluation against a transcribed reference set of nine acts and sixty-nine fields measures an ANLS of 0.967, an exact-match F1 of 0.926, and a zero hallucination rate. It also surfaced genuine defects — a misread year, systematic given-name/surname inversions under certain national conventions — which are documented rather than hidden.

Keywords: document information extraction, vision-language models, optical character recognition, civil registration, legal identity, OPENCRVS, evaluation, ANLS.

Table des matières

Introduction générale	1
Le papier comme obstacle à l'identité légale	1
Le sujet du stage	1
Le fil conducteur : ne jamais affirmer faux	1
Organisation du rapport	2
1 Cadre général du projet	3
1.1 Organisme d'accueil	3
1.1.1 Présentation	3
1.1.2 Positionnement du stage dans l'organisation	3
1.2 Contexte : l'état civil et l'identité légale	3
1.2.1 Ce qu'est un système d'état civil	3
1.2.2 L'enjeu du stock papier	4
1.3 Problématique	5
1.4 Étude de l'existant	5
1.5 Objectifs du stage	6
1.6 Méthodologie de travail	7
1.6.1 Démarche adoptée	7
1.6.2 Planning effectif	7
1.7 Conclusion du chapitre	8
2 État de l'art	9
2.1 La reconnaissance optique de caractères	9
2.1.1 Principe et maturité	9
2.1.2 Leurs limites sur le corpus étudié	9
2.2 Les modèles vision-langage	9
2.2.1 Principe	9
2.2.2 Intérêt pour un corpus hétérogène	10
2.2.3 La contrepartie : l'hallucination	10
2.3 L'extraction d'informations clés	10
2.4 Les métriques d'évaluation	10
2.4.1 Pourquoi cette question mérite un examen attentif	10
2.4.2 Les métriques de recouvrement de n-grammes	10
2.4.3 Les métriques fondées sur la distance d'édition	11
2.4.4 Les métriques structurées	11
2.4.5 Synthèse des métriques retenues	11
2.5 OpenCRVS, le registre civil cible	12
2.5.1 Présentation	12
2.5.2 Le point d'entrée exploité	12
2.5.3 La configuration par pays	12
2.6 Conclusion du chapitre	12
3 Analyse et conception	13

3.1	Analyse des besoins	13
3.1.1	Besoins fonctionnels	13
3.1.2	Besoins non fonctionnels	13
3.1.3	Acteurs et cas d'utilisation	14
3.2	Le principe de conception : ne jamais affirmer faux	14
3.2.1	Formulation	14
3.2.2	Traduction concrète	14
3.3	Architecture générale	15
3.4	Conception du pipeline d'extraction	16
3.4.1	Décomposition en étapes	16
3.4.2	Justification de la double extraction	16
3.4.3	Conception des packs pays	16
3.5	Conception de l'intégration à OpenCRVS	17
3.5.1	Deux voies complémentaires	17
3.5.2	Enchaînement de la voie intégrée	17
3.6	Modèle de données	17
3.7	Conclusion du chapitre	18
4	Réalisation	19
4.1	Environnement technique	19
4.2	Réalisation du pipeline	19
4.2.1	Prétraitement	19
4.2.2	Localisation des champs	19
4.2.3	Extraction en deux passes	20
4.2.4	Validation et score de confiance	21
4.3	Les packs pays	21
4.4	L'application web	21
4.5	Intégration à OpenCRVS	21
4.5.1	Le mapping vers la déclaration	21
4.5.2	Voie par notification	22
4.5.3	Voie intégrée au formulaire	22
4.6	Difficultés rencontrées	22
4.7	Industrialisation de l'environnement	23
4.8	Conclusion du chapitre	24
5	Évaluation et résultats	25
5.1	Deux questions distinctes	25
5.2	Protocole d'évaluation de la justesse	25
5.2.1	Constitution du jeu de référence	25
5.2.2	Traitement particulier des noms	25
5.2.3	Métriques retenues	26
5.3	Résultats de justesse	26
5.4	Erreurs relevées	27
5.4.1	Le défaut systématique : l'ordre des noms	28
5.5	Rendement sur le lot d'échantillons	28
5.6	Limites de la démarche	29
5.7	Reproductibilité	29
5.8	Conclusion du chapitre	30

Conclusion générale	31
Bilan du travail réalisé	31
Ce que la démarche a apporté	31
Limites	31
Perspectives	32
Apport personnel	32
Bibliographie et webographie	33
Extraction et compréhension de documents	33
Métriques d'évaluation	33
État civil et identité légale	33
Annexes	34
Annexe A — Structure du rapport d'extraction	34
Annexe B — Commandes principales	34
Annexe C — Pays couverts	35
Annexe D — Éléments à compléter avant remise	35

Liste des figures

Figure 1	Positionnement du stagiaire dans l'organisation d'accueil	3
Figure 2	Extrait de naissance tunisien du corpus : document bilingue, mise en page en colonnes, tampons superposés au texte	4
Figure 3	Déroulement effectif du stage sur onze semaines	7
Figure 4	Diagramme des cas d'utilisation	14
Figure 5	Traitement d'un champ selon sa validité de format et sa confiance	15
Figure 6	Architecture générale et frontière avec OpenCRVS	15
Figure 7	Étapes du pipeline d'extraction	16
Figure 8	Diagramme de séquence du pré-remplissage dans le formulaire	17
Figure 9	Visualisation des zones détectées, produite pour chaque document et servant au contrôle qualité de la localisation	20
Figure 10	Similarité ANLS par champ évalué	27
Figure 11	Proportion de champs strictement exacts par document	27
Figure 12	Répartition des champs par bande de confiance	29

Liste des tableaux

Tableau 1	Comparaison des approches envisageables pour l'extraction	6
Tableau 2	Métriques d'évaluation retenues et justification de leur emploi	12
Tableau 3	Besoins fonctionnels du système	13
Tableau 4	Besoins non fonctionnels et critères d'acceptation	13
Tableau 5	Structure du rapport produit pour chaque document	18
Tableau 6	Environnement technique du projet	19
Tableau 7	Typologie des documents du corpus par famille de mise en page	21
Tableau 8	Principales difficultés techniques rencontrées et leur résolution	23
Tableau 9	Résultats de justesse sur neuf actes et soixante-neuf champs	26
Tableau 10	Champs erronés ou manquants relevés par l'évaluation	27
Tableau 11	Rendement mesuré sur le lot d'échantillons	28

Liste des acronymes

Acronyme	Signification
ANLS	<i>Average Normalized Levenshtein Similarity</i> — similarité de Levenshtein normalisée moyenne, métrique de référence pour l'extraction documentaire
API	<i>Application Programming Interface</i> — interface de programmation applicative
CER	<i>Character Error Rate</i> — taux d'erreur au niveau du caractère
CRVS	<i>Civil Registration and Vital Statistics</i> — enregistrement des faits d'état civil et statistiques vitales
CSV	<i>Comma-Separated Values</i> — format de fichier tabulaire
DocVQA	<i>Document Visual Question Answering</i> — jeu de données et référentiel d'évaluation sur documents
F1	Moyenne harmonique de la précision et du rappel
HTTP	<i>HyperText Transfer Protocol</i> — protocole de transfert hypertexte
ISO	<i>International Organization for Standardization</i> — ici, format de date ISO 8601
JSON	<i>JavaScript Object Notation</i> — format d'échange de données structurées
KIE	<i>Key Information Extraction</i> — extraction d'informations clés d'un document
LLM	<i>Large Language Model</i> — grand modèle de langage
MinIO	Service de stockage d'objets compatible S3, utilisé par OpenCRVS pour les pièces jointes
MOSIP	<i>Modular Open Source Identity Platform</i> — plateforme d'identité numérique open source
OCR	<i>Optical Character Recognition</i> — reconnaissance optique de caractères
ODD	Objectifs de Développement Durable des Nations unies
OpenCRVS	Registre civil numérique open source
PDF	<i>Portable Document Format</i> — format de document portable
QR	<i>Quick Response</i> — code-barres bidimensionnel
REST	<i>Representational State Transfer</i> — style d'architecture d'API web
ROUGE	<i>Recall-Oriented Understudy for Gisting Evaluation</i> — famille de métriques de recouvrement de n-grammes
SVG	<i>Scalable Vector Graphics</i> — format d'image vectorielle
UUID	<i>Universally Unique Identifier</i> — identifiant unique universel
VLM	<i>Vision-Language Model</i> — modèle vision-langage, traitant conjointement image et texte
WER	<i>Word Error Rate</i> — taux d'erreur au niveau du mot
WSL	<i>Windows Subsystem for Linux</i> — sous-système Linux pour Windows

Introduction générale

Le papier comme obstacle à l'identité légale

Exister légalement suppose de pouvoir le prouver. L'acte de naissance est le document qui ouvre l'accès à l'école, aux soins, à l'héritage, au vote et à l'emploi formel : sans lui, une personne demeure administrativement invisible. Les Nations unies en ont fait une cible explicite des Objectifs de Développement Durable, la cible 16.9 visant à garantir à tous une identité juridique d'ici 2030, y compris l'enregistrement des naissances.

Or, dans de nombreux pays, une part considérable des actes existants n'est disponible que sur papier : registres reliés conservés en mairie, copies intégrales dactylographiées, extraits traduits, souches de volets. Ces documents sont vulnérables — un incendie, une inondation ou simplement le temps suffisent à les faire disparaître — et surtout inexploitable par les administrations modernes, qui raisonnent sur des bases de données.

La numérisation de ces fonds est donc un enjeu de politique publique. Mais elle se heurte à un obstacle très concret, rarement mis en avant : la ressaisie. Un agent qui numérise un registre ne se contente pas de le photographier ; il doit relire chaque acte et retaper chaque champ dans un formulaire. Cette opération est lente, coûteuse, fastidieuse, et introduit ses propres erreurs.

Le sujet du stage

Le présent stage part de ce constat. Il pose la question suivante : dans quelle mesure les modèles vision-langage récents permettent-ils de transformer la ressaisie en simple vérification ?

L'objectif n'est pas de supprimer l'humain de la boucle. Un acte d'état civil est un document juridique : une erreur sur une date de naissance ou une filiation a des conséquences durables sur la vie d'une personne. L'objectif est de déplacer le travail humain, en le faisant passer de la saisie — mécanique, répétitive, sans valeur ajoutée — à la vérification, qui mobilise le jugement.

Le travail réalisé comporte trois volets :

1. une chaîne de traitement qui lit un acte scanné et en extrait des champs structurés assortis d'un score de confiance, couvrant vingt-sept pays ;
2. une application web permettant le dépôt des documents, leur suivi et la correction humaine des valeurs extraites ;
3. une intégration au registre civil numérique OPENCRVS, par laquelle les valeurs extraites pré-remplissent une déclaration de naissance.

Le fil conducteur : ne jamais affirmer faux

Un principe unique gouverne les choix de conception de bout en bout, et il mérite d'être énoncé dès l'introduction car il explique de nombreuses décisions qui pourraient autrement paraître trop prudentes : *le système préfère avouer son incertitude plutôt qu'affirmer une valeur fausse avec assurance.*

Un OCR qui se trompe en le signalant fait perdre quelques secondes à l'officier. Un OCR qui se trompe en paraissant sûr de lui introduit une erreur dans un registre d'état civil, où elle peut demeurer des

décennies. Ces deux erreurs n'ont pas le même coût, et le système est construit en conséquence : seuils de confiance explicites, signalement des valeurs douteuses, refus de déduire ce que le document ne dit pas.

Ce principe a une conséquence directe sur l'évaluation, présentée au chapitre 5 : elle ne cherche pas à produire le chiffre le plus flatteur, mais le chiffre le plus informatif, et elle expose ses échecs.

Organisation du rapport

Le présent document suit la progression du travail.

Le **chapitre 1** situe le projet : l'organisme d'accueil, le contexte de l'état civil, la problématique, l'étude de l'existant et la méthodologie adoptée.

Le **chapitre 2** dresse l'état de l'art : reconnaissance optique classique, modèles vision-langage, extraction d'informations clés, métriques d'évaluation propres au domaine documentaire, et présentation d'OPENCRRVS.

Le **chapitre 3** expose l'analyse et la conception : besoins, cas d'utilisation, architecture générale, conception du pipeline, formalisation du principe d'honnêteté et conception de l'intégration.

Le **chapitre 4** détaille la réalisation, étape par étape, ainsi que les difficultés techniques rencontrées et la manière dont elles ont été résolues.

Le **chapitre 5** présente le protocole d'évaluation, les métriques retenues et leur justification, les résultats obtenus, les erreurs relevées et les limites de la démarche.

La **conclusion** dresse le bilan et ouvre sur les perspectives.

Cadre général du projet

Ce chapitre situe le travail réalisé : l'organisme qui l'a accueilli, le contexte métier dans lequel il s'inscrit, la problématique précise à laquelle il répond, ce qui existait déjà pour la traiter, et la manière dont le stage a été conduit.

1.1 Organisme d'accueil

1.1.1 Présentation


à compléter : présentation de l'organisme : activité, taille, implantation, positionnement

À renseigner

Cette section doit décrire l'organisme d'accueil : son domaine d'activité, ses effectifs, son implantation géographique et son positionnement sur le marché. Ces éléments n'ont pas été inventés ici : un rapport signé par un encadrant ne peut pas contenir d'affirmations invérifiables sur la structure qui l'accueille.

1.1.2 Positionnement du stage dans l'organisation

Le stage s'est déroulé au sein de à compléter : département ou practice, équipe intervenant sur les projets d'infrastructure publique numérique. La Figure 1 situe le stagiaire dans la structure.



Les mentions « à compléter » doivent être renseignées avant remise : elles ne peuvent pas être devinées.

Figure 1 — Positionnement du stagiaire dans l'organisation d'accueil

1.2 Contexte : l'état civil et l'identité légale

1.2.1 Ce qu'est un système d'état civil

Un système d'enregistrement des faits d'état civil, désigné dans la littérature par l'acronyme CRVS, a pour fonction d'enregistrer de manière continue, permanente et obligatoire les événements qui jalonnent la vie juridique d'une personne : naissance, mariage, divorce, décès. Il remplit deux rôles distincts que l'on confond souvent :

Rôle juridique fournir à chaque individu la preuve de son identité, de sa filiation et de sa nationalité. C'est ce qui permet d'être scolarisé, soigné, employé, de voyager, d'hériter et de voter.

Rôle statistique produire les données démographiques qui fondent les politiques publiques. Un État qui ignore combien d'enfants naissent et où ne peut pas planifier ses écoles ni ses centres de santé.

1.2.2 L'enjeu du stock papier

La difficulté ne porte pas seulement sur les naissances futures, mais sur le stock accumulé. Des décennies d'actes reposent dans des registres papier. Trois caractéristiques rendent leur traitement automatique délicat :

L'hétérogénéité chaque pays, et souvent chaque commune, dispose de sa propre mise en page. Le corpus rassemblé durant ce stage comporte des copies intégrales narratives, des formulaires à cases, des volets à souche, des extraits traduits et des registres remplis à la main.

La dégradation photocopies de photocopies, encre pâlie, tampons superposés au texte, pages gondolées, photographies prises de travers au téléphone.

Le multilinguisme actes bilingues français/arabe, traductions certifiées, toponymes translittérés de plusieurs manières.

La Figure 2 présente un acte représentatif du corpus, tel qu'il se présente réellement à la chaîne de traitement.

REPUBLICQUE TUNISIENNE
MINISTRE DE L'INTERIEUR

Gouvernorat : MEDENINE
Délégation : BEN GUERDANE
Commune : BEN GUERDANE
Arrondis. com. : Jmila
Secteur :

0511011

Année : 1981
Acte N° : 24
— Déclaration :
— ou jugement :

**EXTRAIT DES REGISTRES
DE L'ETAT CIVIL
NAISSANCE
(VERSION FRANÇAISE)**

NOM PRENOMS	YAHIA* ALI*
Date de naissance Jour, mois et année (en toutes lettres)	LE DIX MARS MILLE NEUF CENT QUATRE-VINGT ET UN *
Lieu de naissance	BEN GUERDANE*
Sexe	MASCULIN*
Nom, prénoms, profession et nationalité du père	HEDI BEN AMMAR BEN DHAOU* TUNISIENNE*
Nom, prénoms, profession et nationalité de la mère	MABROUKA BENT MOHAMED BEN ONE YAHIA* TUNISIENNE*
Date de la déclaration (jour, mois, année, heure)	LE ONZE MARS MILLE NEUF CENT QUATRE-VINGT ET UN *
Nom, prénoms et profession du déclarant ou le Tribunal	MONTASSAR AZREG *
Nom, prénoms et qualité de l'officier de l'état civil	LAJIL BELGACEM*
OBSERVATIONS NEANT <i>Déclaré en vue de mariage</i>	

Imprimerie Officielle

100 millions BEN GUERDANE

40 AVRIL 2017

Four version française, certifiée conforme à l'original

Note : Tout faux, toute altération dans les actes de l'état civil donne lieu aux poursuites judiciaires conformément aux lois régissant l'état civil et au code pénal.

L'Officier de l'état civil
Président de la Délégation Spéciale
de la Commune de Benguerdene
Kouzi Omar

FEU00004

14 *transport*

Figure 2 — Extrait de naissance tunisien du corpus : document bilingue, mise en page en colonnes, tampons superposés au texte

1.3 Problématique

La numérisation d'un fonds d'actes se heurte à un goulot d'étranglement humain. Photographier un registre est rapide ; en saisir le contenu ne l'est pas. Pour chaque acte, un agent doit lire le document, identifier les informations pertinentes au milieu de formules juridiques, puis les retaper dans un formulaire comportant plusieurs dizaines de champs.

Cette opération pose trois problèmes :

1. **Le coût** : le temps de saisie est le principal poste de dépense d'un projet de numérisation rétrospective.
2. **La qualité** : la saisie répétitive engendre ses propres erreurs, et celles-ci sont d'autant plus difficiles à détecter qu'elles portent sur des données que personne ne relit avant leur usage effectif.
3. **Le passage à l'échelle** : la vitesse de traitement est bornée par le nombre d'agents disponibles.

La question posée par ce stage est donc la suivante :

Problématique

Comment concevoir un système capable d'extraire automatiquement les données d'un acte d'état civil scanné, quel que soit son pays d'origine et son état de conservation, et de les injecter dans un registre civil numérique, de façon suffisamment fiable pour que l'agent passe de la saisie à la vérification — sans jamais introduire dans le registre une erreur présentée comme certaine ?

La dernière partie de cette question n'est pas ornementale. Un système d'extraction qui atteindrait une exactitude élevée mais présenterait ses erreurs avec la même assurance que ses réussites serait inutilisable pour un registre d'état civil : l'agent, ne sachant pas où porter son attention, devrait tout revérifier, ce qui annulerait le gain.

1.4 Étude de l'existant

Plusieurs familles de solutions permettent d'extraire de l'information d'un document. Le Tableau 1 les compare au regard des contraintes du projet.

Approche	Principe	Atouts	Limites pour ce projet	Retenue
OCR classique (Tesseract)	Reconnaissance caractère par caractère, sans compréhension	Gratuit, local, rapide, mature	Restitue du texte brut sans structure ; s'effondre sur scans dégradés et mises en page complexes	Non — conservé pour la localisation des étiquettes
OCR commercial (services cloud)	OCR + extraction structurée via API propriétaire	Bonne qualité, prêt à l'emploi	Coût à l'acte ; données d'état civil envoyées à un tiers ; peu adaptable aux mises en page nationales	Non
Modèles spécialisés (LayoutLM, Donut)	Modèles entraînés pour la compréhension de documents	Excellents résultats sur leurs domaines	Nécessitent un corpus annoté conséquent, indisponible ici	Non
Modèles vision-langage généralistes	Le modèle voit l'image et répond selon un schéma demandé	Aucun entraînement requis ; robuste à l'hétérogénéité de sortie structurée	Coût par appel ; risque d'hallucination à maîtriser explicitement	Oui
Saisie manuelle	Un agent lit et re-tape	Fiabilité du jugement humain	Coût et lentueur : le problème que l'on cherche à résoudre	Non — mais conservée en vérification

Tableau 1 — Comparaison des approches envisageables pour l'extraction

Le choix s'est porté sur les modèles vision-langage pour une raison décisive : ils sont les seuls à absorber l'hétérogénéité du corpus sans corpus annoté préalable. Un modèle spécialisé aurait exigé des milliers d'actes annotés par pays ; un modèle vision-langage accepte un schéma de champs décrit en langage naturel et s'y conforme.

Ce choix a un revers, assumé et traité tout au long du projet : un modèle génératif peut produire une valeur plausible mais fausse. C'est précisément ce que le principe d'honnêteté, formalisé au chapitre 3, vise à contenir.

1.5 Objectifs du stage

Les objectifs ont été formulés en début de stage puis affinés au contact des premières difficultés.

Objectif principal réduire significativement le travail de saisie nécessaire à l'enregistrement d'un acte de naissance dans un registre civil numérique.

Objectifs techniques

- concevoir une chaîne de traitement générique, capable de traiter des actes de plusieurs pays sans réécriture de code ;
- produire pour chaque champ extrait un score de confiance exploitable ;
- intégrer le résultat à OPENCRVS sans modifier son code source ;
- fournir une interface de vérification humaine et capitaliser les corrections en vue d'améliorations ultérieures.

Objectifs méthodologiques

- évaluer le système avec les métriques du domaine plutôt qu'avec des indicateurs improvisés ;
- documenter les limites et les échecs au même titre que les réussites.

1.6 Méthodologie de travail

1.6.1 Démarche adoptée

Le stage a été conduit de manière incrémentale : construire d'abord une chaîne minimale fonctionnelle de bout en bout, puis l'élargir et la durcir. Ce choix s'est révélé judicieux, car il a permis de valider très tôt l'hypothèse centrale — un modèle vision-langage lit-il correctement un acte dégradé ? — avant d'investir dans l'industrialisation.

Chaque étape s'est achevée par une vérification sur documents réels plutôt que sur cas de test synthétiques. Le code a été versionné en continu, l'historique du dépôt servant de trace datée des décisions techniques.

1.6.2 Planning effectif

La Figure 3 présente le déroulement réel du stage, reconstitué à partir de l'historique du dépôt.




Figure 3 — Déroulement effectif du stage sur onze semaines

Deux périodes méritent un commentaire. Les semaines 7 à 9 comportent peu de livrables logiciels : elles ont été consacrées à l'étude de la littérature d'évaluation et à l'analyse du mécanisme interne des formulaires OPENCRVS, travail préparatoire sans lequel l'intégration native réalisée ensuite n'aurait pas été possible. La dernière semaine a été consacrée à l'évaluation approfondie et à la rédaction.

1.7 Conclusion du chapitre

Le projet répond à un besoin identifié — la ressaisie comme goulot d'étranglement de la numérisation de l'état civil — au moyen d'une technologie choisie pour sa capacité à absorber l'hétérogénéité documentaire sans corpus annoté. Le chapitre suivant examine les fondements techniques sur lesquels cette technologie repose, ainsi que les moyens dont on dispose pour en mesurer sérieusement la qualité.

État de l'art

Ce chapitre présente les techniques disponibles pour lire un document et en extraire de l'information structurée, puis les moyens d'en mesurer la qualité. Cette seconde partie occupe une place inhabituellement importante : le choix des métriques conditionne ce que l'on est capable de constater, et un mauvais choix peut rendre invisible l'erreur qui compte le plus.

2.1 La reconnaissance optique de caractères

2.1.1 Principe et maturité

La reconnaissance optique de caractères, ou OCR, convertit une image de texte en texte encodé. Les moteurs classiques procèdent par segmentation en lignes puis en caractères, suivie d'une classification de chaque forme. Le moteur libre Tesseract, développé depuis les années 1980 et maintenu aujourd'hui par la communauté, en constitue la référence.

Ces moteurs sont matures, rapides, gratuits et fonctionnent localement — quatre propriétés précieuses pour des données sensibles.

2.1.2 Leurs limites sur le corpus étudié

Les essais menés en début de stage ont montré trois limites rédhibitoires pour un usage direct :

L'absence de structure un moteur classique restitue une suite de mots. Il ne distingue pas le nom de l'enfant de celui du père : cette distinction relève de la compréhension du document, non de la reconnaissance des formes.

La sensibilité à la dégradation sur photocopie pâlie ou tampon superposé au texte, le taux d'erreur devient tel que le résultat n'est plus exploitable.

La rigidité face à la mise en page colonnes, encadrés, texte manuscrit inséré dans un formulaire imprimé — autant de configurations qui perturbent la segmentation.

Ces limites n'ont pas conduit à écarter complètement l'OCR classique. Il reste utilisé dans le système réalisé, mais pour une tâche où il excelle : repérer les *étiquettes imprimées* d'un formulaire, textes nets, courts et connus à l'avance, afin de localiser les zones où lire les valeurs.

2.2 Les modèles vision-langage

2.2.1 Principe

Un modèle vision-langage, ou VLM, traite conjointement une image et une consigne textuelle. Contrairement à un moteur OCR, il ne se contente pas de transcrire : il peut répondre à une question portant sur l'image, ou produire une sortie conforme à un schéma décrit dans la consigne.

Appliqué à un acte d'état civil, ce fonctionnement change la nature du problème. Plutôt que de transcrire puis de tenter d'interpréter, on demande directement au modèle les informations recherchées, en lui décrivant les champs attendus. Le modèle exploite alors le contexte visuel — l'étiquette voisine, la position dans la page, la structure du formulaire — de la même manière qu'un lecteur humain.

2.2.2 Intérêt pour un corpus hétérogène

L'atout décisif dans le cadre de ce projet est l'absence d'entraînement préalable. Un modèle spécialisé dans la compréhension de documents, comme la famille LayoutLM ou l'approche sans OCR de Donut, produit d'excellents résultats sur le domaine pour lequel il a été entraîné, mais exige un corpus annoté conséquent. Un tel corpus n'existe pas pour les actes d'état civil africains, et le constituer aurait dépassé la durée du stage.

Un modèle vision-langage généraliste accepte au contraire un schéma décrit en langage naturel, ce qui permet d'ajouter un pays en écrivant une description de champs plutôt qu'en collectant et annotant des milliers d'exemples.

2.2.3 La contrepartie : l'hallucination

Cet atout a un revers qu'il serait malhonnête de minimiser. Un modèle génératif produit toujours une réponse, y compris lorsqu'il ne sait pas. Il peut inventer une valeur plausible — une date bien formée, un nom vraisemblable — sans que rien dans la forme de la réponse ne signale l'invention.

Pour un registre d'état civil, c'est le mode de défaillance le plus grave. Une date manifestement absurde serait détectée ; une date plausible mais fausse entrera dans le registre et y demeurera. C'est ce constat qui a motivé le principe de conception exposé au chapitre suivant, et qui explique que le taux d'hallucination figure parmi les métriques d'évaluation retenues.

2.3 L'extraction d'informations clés

L'extraction d'informations clés, ou KIE, désigne la tâche consistant à produire, à partir d'un document, un ensemble de couples champ-valeur conformes à un schéma. Elle se distingue de la simple transcription : la sortie attendue est structurée, et l'ordre du texte dans la page n'a pas d'importance.

Cette tâche dispose de jeux de données de référence bien établis — reçus et factures pour SROIE et CORD, documents administratifs variés pour DocVQA — et c'est de cette littérature que proviennent les métriques employées au chapitre 5.

2.4 Les métriques d'évaluation

2.4.1 Pourquoi cette question mérite un examen attentif

Mesurer la qualité d'une extraction documentaire n'a rien d'évident, et le choix d'une métrique inadaptée conduit à des conclusions trompeuses. Une métrique trop stricte considère « Céline » et « CELINE » comme deux réponses différentes et sous-estime le système ; une métrique trop permissive accorde un bon score à une date fausse et le surestime.

2.4.2 Les métriques de recouvrement de n-grammes

BLEU et ROUGE, issues respectivement de la traduction automatique et du résumé, mesurent le recouvrement de séquences de mots entre la réponse produite et la référence. Elles sont peu coûteuses, reproductibles, et largement citées.

Elles sont cependant mal adaptées à l'extraction documentaire, pour des raisons bien identifiées dans la littérature :

- elles pénalisent lourdement une paraphrase correcte ;
- elles ignorent la correctness factuelle : une réponse fluide mais fausse peut obtenir un score élevé ;
- elles souffrent d'un biais de longueur qui désavantage les réponses courtes, précisément la forme que prend un champ extrait ;
- elles s'appliquent mal aux sorties structurées.

Dans le présent travail, elles ne sont donc pas retenues comme indicateur principal. Elles figurent en annexe du rapport d'évaluation, calculées sur le seul champ en texte libre, à titre de comparabilité.

2.4.3 Les métriques fondées sur la distance d'édition

La famille des métriques de distance d'édition constitue le standard de fait pour l'extraction documentaire. Elle repose sur la distance de Levenshtein, c'est-à-dire le nombre minimal d'insertions, suppressions et substitutions de caractères permettant de passer d'une chaîne à l'autre.

CER et WER taux d'erreur rapportés respectivement au caractère et au mot. Ils constituent la vue « transcription » de la qualité.

ANLS la similarité de Levenshtein normalisée moyenne, métrique principale du référentiel DocVQA. Elle mesure une similarité comprise entre 0 et 1, puis l'annule en dessous d'un seuil, fixé par convention à 0,5.

Ce seuillage n'est pas un détail technique : il traduit une décision de fond. Une réponse à moitié correcte n'est pas, pour un officier d'état civil, une demi-bonne réponse — c'est une mauvaise réponse. La métrique tolère la coquille mais refuse le crédit partiel à une valeur substantiellement fausse.

2.4.4 Les métriques structurées

L'extraction peut aussi se lire comme une tâche de recherche d'information, ce qui autorise l'emploi de la précision, du rappel et de leur moyenne harmonique F1, appliqués au niveau du champ :

- la **précision** répond à la question : parmi les valeurs que le système affirme avoir lues, combien sont exactes ?
- le **rappel** répond à : parmi les valeurs réellement présentes dans l'acte, combien le système a-t-il produites ?

Pour un registre d'état civil, la précision prime sur le rappel. Un champ non rempli coûte une saisie ; un champ rempli faux coûte une erreur dans un acte juridique.

S'y ajoutent deux mesures indispensables ici :

Le taux d'hallucination la proportion de champs pour lesquels le système produit une valeur alors que le document n'en contient aucune.

La conformité au schéma la proportion de valeurs directement exploitables par le système cible — date au format ISO, sexe appartenant à l'énumération attendue.

2.4.5 Synthèse des métriques retenues

Le Tableau 2 récapitule les métriques employées au chapitre 5 et la raison de leur présence.

Métrique	Ce qu'elle mesure	Pourquoi elle est retenue
ANLS	Similarité de Levenshtein normalisée, seuillée à 0,5	Métrique principale du domaine ; tolère la coquille, refuse le crédit partiel à une valeur fausse
CER / WER	Taux d'erreur au caractère et au mot	Vue transcription, comparable à la littérature OCR
Précision / Rappel / F1	Extraction vue comme recherche d'information	Distingue « ne rien dire » de « dire faux », distinction centrale ici
Correspondance approchée	F1 avec tolérance de similarité $\geq 0,8$	Évite qu'un accent ou un trait d'union compte comme une erreur totale
Taux d'hallucination	Valeurs produites pour un champ absent du document	Mode de défaillance le plus grave pour un registre d'état civil
Conformité au schéma	Valeurs exploitables telles quelles par la cible	Une valeur juste mais mal formatée reste inutilisable
BLEU / ROUGE	Recouvrement de n-grammes	En annexe seulement, pour comparabilité : aveugles à une date fausse

Tableau 2 — Métriques d'évaluation retenues et justification de leur emploi

2.5 OpenCRVS, le registre civil cible

2.5.1 Présentation

OPENCRVS est une plateforme libre d'enregistrement des faits d'état civil, conçue comme un bien public numérique et déployée par plusieurs États. Elle couvre le cycle complet d'un dossier : déclaration, validation, enregistrement, délivrance de certificat.

Son architecture repose sur une constellation de microservices — authentification, passerelle applicative, gestion des événements, recherche, documents, notifications — s'appuyant sur des composants d'infrastructure classiques : base documentaire, moteur de recherche, base relationnelle, stockage d'objets.

2.5.2 Le point d'entrée exploité

OPENCRVS expose une interface de *notification d'événement*, conçue pour qu'un système tiers de confiance — typiquement un établissement de santé annonçant une naissance — dépose une déclaration incomplète que l'officier complétera ensuite.

Cette interface correspond exactement au besoin du projet : une chaîne d'extraction n'a pas vocation à enregistrer un acte, mais à préparer le travail de l'officier. Elle a donc été retenue comme voie d'intégration principale, et une seconde voie, plus intégrée, a été développée par la suite.

2.5.3 La configuration par pays

Un aspect déterminant pour ce travail est qu'OPENCRVS sépare son cœur applicatif de sa configuration nationale. Les formulaires, les listes de lieux et les règles propres à un pays résident dans un dépôt distinct. Cette séparation a permis d'ajouter un panneau de numérisation au formulaire de déclaration *sans modifier une seule ligne du cœur d'OPENCRVS*, ce qui garantit la compatibilité avec les mises à jour futures.

2.6 Conclusion du chapitre

L'analyse conduit à trois choix structurants. Les modèles vision-langage sont retenus pour leur capacité à absorber l'hétérogénéité documentaire sans corpus annoté, au prix d'un risque d'hallucination qu'il faudra contenir explicitement. Les métriques d'évaluation seront empruntées à la littérature de l'extraction documentaire, et non aux métriques de génération de texte. L'intégration s'appuiera sur l'interface de notification d'OPENCRVS et sur sa configuration par pays, sans toucher au cœur applicatif.

Le chapitre suivant traduit ces choix en une conception.

Analyse et conception

Ce chapitre traduit les choix technologiques du chapitre précédent en une conception : besoins, acteurs, architecture, décomposition de la chaîne de traitement, et formalisation du principe qui gouverne l'ensemble.

3.1 Analyse des besoins

3.1.1 Besoins fonctionnels

Les besoins ont été formulés du point de vue de l'officier d'état civil, utilisateur final du système.

Réf.	Besoin fonctionnel	Priorité
BF1	Déposer un acte scanné depuis un poste de travail	Haute
BF2	Photographier un acte avec un téléphone et l'envoyer au traitement	Moyenne
BF3	Extraire automatiquement les champs de l'acte, quel que soit le pays d'origine	Haute
BF4	Associer à chaque champ extrait un score de confiance interprétable	Haute
BF5	Consulter les valeurs extraites en regard de la zone du document dont elles proviennent	Haute
BF6	Corriger une valeur erronée et conserver la correction	Moyenne
BF7	Pré-remplir une déclaration de naissance dans OpenCRVS	Haute
BF8	Joindre le scan d'origine à la déclaration	Moyenne
BF9	Signaler explicitement les valeurs incertaines à l'officier	Haute
BF10	Déposer le scan sans quitter le formulaire OpenCRVS	Haute

Tableau 3 — Besoins fonctionnels du système

3.1.2 Besoins non fonctionnels

Réf.	Besoin non fonctionnel	Critère retenu
BNF1	Temps de traitement compatible avec un usage au guichet	Moins de deux minutes par acte
BNF2	Extensibilité à de nouveaux pays sans modification du code	Ajout d'un pays par simple fichier de configuration
BNF3	Aucune modification du cœur applicatif d'OpenCRVS	Intégration par API et configuration pays uniquement
BNF4	Souveraineté des données en production	Bascule vers un modèle hébergé localement sans changement de code
BNF5	Traçabilité des valeurs produites	Conservation du scan, des zones détectées et des scores
BNF6	Robustesse aux documents dégradés	Dégradation progressive plutôt qu'échec brutal
BNF7	Reproductibilité de l'évaluation	Métriques recalculables par une commande

Tableau 4 — Besoins non fonctionnels et critères d'acceptation

3.1.3 Acteurs et cas d'utilisation

Le système compte deux acteurs. L'**officier d'état civil** dépose les actes, vérifie les valeurs extraites et valide la déclaration. L'**administrateur** configure l'accès du système au registre. La Figure 4 présente les cas d'utilisation.




Figure 4 — Diagramme des cas d'utilisation

3.2 Le principe de conception : ne jamais affirmer faux

3.2.1 Formulation

Le chapitre 2 a identifié l'hallucination comme le mode de défaillance le plus grave d'un modèle génératif appliqué à un registre juridique. La réponse apportée n'est pas un correctif ponctuel mais un principe appliqué à chaque étape de la chaîne :

Principe directeur

À chaque étape, lorsque le système n'est pas en mesure de produire une valeur fiable, il doit rendre son incertitude visible plutôt que produire une valeur qui paraîtra certaine. Une valeur manquante coûte une saisie ; une valeur fautive présentée comme sûre coûte une erreur dans un acte juridique.


3.2.2 Traduction concrète

Ce principe se décline en cinq décisions de conception :

1. **Localisation** : si le gabarit d'un pays ne correspond pas au document présenté, la chaîne bascule vers une localisation par le modèle plutôt que de produire des zones erronées mais d'apparence normale.
2. **Score de confiance** : chaque champ porte un score issu de l'accord entre deux extractions indépendantes et des règles de validation. En dessous d'un seuil, la valeur est pré-remplie mais explicitement signalée « à vérifier ».
3. **Refus de trancher l'ambigu** : une nationalité comme « congolaise », qui correspond à deux États, n'est jamais convertie automatiquement ; la valeur brute reste visible pour l'officier.
4. **Refus de déduire** : la nationalité n'est jamais inférée d'un lieu de naissance. Le corpus lui-même invalide ce raccourci : un acte y mentionne un père né à Dakar et explicitement enregistré comme citoyen français.

5. **Refus de deviner une catégorie** : le lieu d'accouchement — hôpital, domicile ou autre — n'est pas renseigné automatiquement, car l'acte le précise rarement.

La Figure 5 résume l'arbitrage appliqué à chaque champ.




Aucune branche n'invente de valeur : le doute est toujours rendu visible à l'officier.

Figure 5 — Traitement d'un champ selon sa validité de format et sa confiance

3.3 Architecture générale

Le système se compose de trois briques, volontairement découplées, dont la Figure 6 montre l'articulation avec la plateforme cible.



Le service OCR ne modifie jamais le code d'OpenCRVS : il dialogue par l'API et par la configuration pays.

Figure 6 — Architecture générale et frontière avec OpenCRVS

Le pipeline d'extraction cœur du système, il transforme un scan en champs structurés. Il s'exécute en processus séparé, isolé des pannes du serveur web.

L'application web point d'entrée pour le dépôt des documents, le suivi du traitement et la correction humaine.

L'intégration OpenCRVS transforme les champs extraits en déclaration et la transmet, soit par l'interface de notification, soit directement au formulaire.

Ce découplage répond au besoin BNF4 : la brique d'extraction peut changer de modèle sous-jacent — service distant ou modèle hébergé localement — sans que les deux autres en soient affectées.

3.4 Conception du pipeline d'extraction

3.4.1 Décomposition en étapes

La Figure 7 présente les cinq étapes de la chaîne et leurs sorties.




Figure 7 — Étapes du pipeline d'extraction

3.4.2 Justification de la double extraction

L'étape d'extraction procède en deux passes indépendantes : une lecture de la page entière, puis une lecture de chaque zone recadrée. Ce dédoublement, plus coûteux qu'une passe unique, se justifie par deux apports.

La **lecture de la page entière** donne au modèle le contexte : la structure du document, les étiquettes voisines, la logique d'ensemble. La **lecture des recadrages** lui donne la résolution : sur une zone isolée et agrandie, un caractère pâle devient lisible.

Surtout, la comparaison des deux résultats fournit un **signal de confiance gratuit**. Deux lectures indépendantes qui concordent constituent un indice de fiabilité ; deux lectures qui divergent signalent une zone problématique. Ce signal alimente directement le score de chaque champ, et il est réutilisé au chapitre 5 comme mesure interne.

3.4.3 Conception des packs pays

Le besoin BNF2 impose qu'ajouter un pays ne demande pas de modifier le code. La conception isole donc tout ce qui est propre à un pays dans un répertoire de configuration comportant deux fichiers : la description des champs attendus, et un lexique de lieux qui oriente la lecture vers les graphies correctes.

Un point mérite d'être signalé, car il a une conséquence directe sur l'intégration : chaque pays nomme ses champs dans son propre vocabulaire. Un même concept — le nom de l'enfant — peut s'appeler `enfant_nom` dans un pack, se scinder en `nom` et `prenoms` dans un autre, ou apparaître comme `enfant_nom_complet` dans un troisième. Une table de correspondance ramène tous ces vocabulaires vers les identifiants attendus par OPENCRVS.

3.5 Conception de l'intégration à OpenCRVS

3.5.1 Deux voies complémentaires

Deux voies ont été conçues, répondant à deux usages différents.

La **voie par notification** convient au traitement par lots : un fonds d'actes est numérisé, traité, et les déclarations pré-remplies apparaissent dans la file de travail de l'officier, qui les traite ensuite à son rythme.

La **voie intégrée au formulaire** convient au traitement à l'unité, au guichet : l'officier ouvre une déclaration, dépose le scan sans quitter OPENCRVS, et voit les champs se remplir devant lui.

3.5.2 Enchaînement de la voie intégrée

La Figure 8 détaille l'enchaînement des échanges de la voie intégrée, celle qui a demandé le plus d'analyse.




Figure 8 — Diagramme de séquence du pré-remplissage dans le formulaire

Deux contraintes de la plateforme ont façonné cette conception, et méritent d'être explicitées car elles ne sont pas documentées :

Le transport du fichier le type de champ permettant à un formulaire OPENCRVS d'appeler un service externe ne transmet que du texte structuré, jamais des octets de fichier. Le scan ne peut donc pas être envoyé directement au service d'extraction. La conception contourne cette contrainte en laissant le formulaire téléverser le fichier vers le stockage d'OPENCRVS, puis en ne transmettant au service que le *chemin* du fichier, que celui-ci va lire lui-même.

La propagation des valeurs un champ de formulaire ne se synchronise sur une source externe que si sa configuration déclare cette source comme parente. La seule déclaration de la valeur à lire reste sans effet. Cette subtilité a donné lieu à une difficulté de mise au point détaillée au chapitre 4.

3.6 Modèle de données

Chaque document traité produit un rapport structuré unique, qui constitue le contrat entre le pipeline et tout ce qui le consomme. Le Tableau 5 en décrit les attributs principaux.

Attribut	Type	Rôle
doc_id	chaîne	Identifiant du document traité
status	énumération	État global : accepté ou nécessitant relecture
fields_total	entier	Nombre de champs prévus par le pack pays
fields_auto_accepted	entier	Champs dont la confiance dépasse le seuil
localization	objet	Pays détecté, gabarit employé, méthode de localisation, ancres trouvées
fields	dictionnaire	Un objet par champ extrait, décrit ci-dessous

Tableau 5 — Structure du rapport produit pour chaque document

Chaque champ porte non seulement sa valeur, mais la trace de sa production : la valeur lue par la passe page, celle lue par la passe recadrage, l'accord entre les deux, la zone d'origine dans l'image, le score final et la bande de confiance. Cette richesse répond au besoin BNF5 : une valeur doit pouvoir être expliquée, non seulement affichée.

3.7 Conclusion du chapitre

La conception traduit le principe d'honnêteté en décisions concrètes à chaque étage, isole ce qui est propre à un pays dans de la configuration, et prévoit deux voies d'intégration répondant à deux usages distincts. Le chapitre suivant décrit la réalisation effective et les obstacles rencontrés.

Réalisation

Ce chapitre décrit la mise en œuvre effective : l’environnement technique, la réalisation de chaque étape de la chaîne, les deux voies d’intégration, et les difficultés rencontrées avec la manière dont elles ont été résolues.

4.1 Environnement technique

Domaine	Technologie	Rôle dans le projet
Langage	Python 3.12	Pipeline d’extraction, application web, outillage
Web	FastAPI, Uvicorn	Application de dépôt, de suivi et de correction
Vision	OpenCV, Pillow	Prétraitement des images
OCR	Tesseract	Repérage des étiquettes imprimées pour la localisation
Modèle	Modèle vision-langage via API	Extraction des valeurs
PDF	pypdfium2	Conversion des actes fournis en PDF
Comparaison	RapidFuzz	Appariement approché des étiquettes et des lieux
Registre	OpenCRVS v1.9.14	Plateforme cible de l’intégration
Configuration	TypeScript	Panneau ajouté au formulaire de déclaration
Infrastructure	Docker, WSL	Exécution locale de la plateforme OpenCRVS
Tests	pytest	Tests hors-ligne du mapping et des règles
Versionnement	Git	Suivi des évolutions et traçabilité des décisions

Tableau 6 — Environnement technique du projet

4.2 Réalisation du pipeline

4.2.1 Prétraitement

Le prétraitement corrige ce qui gêne la lecture sans altérer le contenu : redressement de l’inclinaison, mise à l’échelle des documents de faible résolution, amélioration du contraste et binarisation. Les documents fournis en PDF sont convertis en image au préalable.

Une décision apparemment mineure s’est révélée importante par la suite : le scan d’origine est conservé intact aux côtés des versions traitées. Elle a permis, lorsque le besoin d’attacher la pièce justificative à la déclaration est apparu, de disposer du document tel que l’officier l’a déposé, et non d’une version retouchée pour la machine.

4.2.2 Localisation des champs

La localisation détermine où lire chaque information. Elle procède en deux temps.

D’abord, une **localisation par gabarit** : les étiquettes imprimées du formulaire sont repérées par OCR classique, puis appariées de manière approchée aux étiquettes attendues du pack pays. Cet appariement approché est nécessaire car l’OCR restitue rarement une étiquette sans faute sur un document dégradé. Les positions trouvées définissent les zones où lire les valeurs.

Ensuite, un **contrôle de fiabilité** : si la proportion de champs effectivement localisés tombe sous un seuil, le gabarit est considéré comme inadapté — mise en page inconnue, page multiple, scan de mauvaise qualité — et la chaîne bascule vers une localisation confiée au modèle vision-langage.

C'est la première application concrète du principe d'honnêteté : plutôt que de produire des zones fausses mais d'apparence normale, le système reconnaît que le gabarit ne convient pas.

La Figure 9 montre la visualisation produite pour contrôle.

REPUBLICQUE TUNISIENNE
MINISTERE DE L'INTERIEUR

MEDENINE
Gouvernement : BEN GUERDANE
Délégation : BEN GUERDANE
Commune :
Arrondis. com. : Jmila
Secteur :

05/10/17

Année : 1981
Acte N° : 24
— Déclaration :
— ou jugement :

**EXTRAIT DES REGISTRES
DE L'ETAT CIVIL**

NAISSANCE
(VERSION FRANÇAISE)

NOM PRENOMS	YAHIA* ALI*
Date de naissance Jour, mois et année (en toutes lettres)	LE DIX MARS MILLE NEUF CENT QUATRE-VINGT ET UN *
Lieu de naissance	BEN GUERDANE*
Sexe	MASCULIN*
Nom, prénoms, profession et nationalité du père	HEDI BEN AMMAR BEN DHAAOU* TUNISIENNE*
Nom, prénoms, profession et nationalité de la mère	MABROUKA BENT MOHAMED BEN ONE YAHIA* TUNISIENNE*
Date de la déclaration (jour, mois, année, heure)	LE ONZE MARS MILLE NEUF CENT QUATRE-VINGT ET UN *
Nom, prénoms et profession du déclarant ou le Tribunal	MONTASSAR AZREG *
Nom, prénoms et qualité de l'officier de l'état civil	LAJIL BELGACEM*

OBSERVATIONS
N E A N T
Déclaré en vue de mariage

Imprimée Officielle
100 millimes BEN GUERDANE
20 AVRIL 2017

Pour version française, certifiée conforme à l'original

L'Officier de l'état civil
Président de la Délégation Spéciale
de la Commune de Benguerdene
Kouz Omar

Note : Tout faux, toute altération dans les actes de l'état civil donne lieu aux poursuites judiciaires conformément aux lois réglementant l'état civil et au code pénal.

Figure 9 — Visualisation des zones détectées, produite pour chaque document et servant au contrôle qualité de la localisation

4.2.3 Extraction en deux passes

L'extraction interroge le modèle deux fois, comme prévu à la conception.

La mise en œuvre initiale traitait chaque zone recadrée par un appel distinct, ce qui portait le temps de traitement à environ dix minutes par document — incompatible avec le besoin BNF1. Trois optimisations ont ramené ce temps à une fourchette de quarante à quatre-vingt-dix secondes :

1. **Le regroupement** : les zones sont envoyées par lots de cinq images par appel plutôt qu'une par une.
2. **La parallélisation** : quatre lots sont traités simultanément.

3. **La limitation du raisonnement** : le budget de réflexion interne du modèle est plafonné, la tâche relevant de la lecture et non du raisonnement.

Une gestion des quotas complète le dispositif : plusieurs clés d'accès sont configurées et la chaîne bascule automatiquement de l'une à l'autre lorsqu'une limite est atteinte.

4.2.4 Validation et score de confiance

La validation convertit et contrôle. Elle transforme les dates écrites en toutes lettres — fréquentes dans les actes narratifs — en dates normalisées, vérifie la cohérence chronologique, et rapproche les lieux du lexique du pays.

Le score de confiance de chaque champ agrège trois signaux : la confiance déclarée par le modèle, l'accord entre les deux passes d'extraction, et le résultat des règles de validation. Les champs sont ensuite répartis en trois bandes, et le seuil retenu détermine ce que l'officier devra relire.

4.3 Les packs pays

Vingt-sept pays sont couverts, chacun décrit par un répertoire de configuration. Le Tableau 7 présente la répartition par type de document, révélatrice de l'hétérogénéité du corpus.

Type de document	Caractéristiques	Exemples de pays
Copie intégrale narrative	Acte rédigé en prose continue, information dispersée dans le texte	Côte d'Ivoire, Madagascar, Algérie
Formulaire à champs étiquetés	Étiquettes imprimées, valeurs dactylographiées ou manuscrites	Mali, Tunisie, Mauritanie
Volet à souche	Feuillet détachable, information condensée	Bénin, Togo
Extrait traduit	Traduction certifiée d'un acte en langue étrangère	Nigéria, Sierra Leone, Afrique du Sud
Registre manuscrit	Acte rempli à la main dans un registre imprimé	Cameroun, Gabon, Sénégal, Rwanda

Tableau 7 — Typologie des documents du corpus par famille de mise en page

Cette diversité justifie a posteriori le choix d'un modèle vision-langage : une approche par gabarit seule n'aurait pas absorbé l'écart entre un acte narratif malgache et un formulaire à cases malien.

4.4 L'application web

L'application web constitue le point d'entrée humain du système. Elle offre trois fonctions.

Le **dépôt** accepte les images et les PDF par glisser-déposer. Il propose également un code QR : l'officier le scanne avec un téléphone, ce qui ouvre une page de capture permettant de photographier l'acte directement. Cette voie répond au cas d'usage réel du terrain, où le poste de travail n'est pas toujours équipé d'un scanner.

Le **sui**vi affiche l'avancement de chaque document. Le traitement s'exécutant en processus séparé, une défaillance sur un document n'interrompt ni le serveur ni les autres traitements.

La **correction** présente chaque valeur extraite en regard du recadrage dont elle provient, les champs les moins sûrs en premier. Chaque correction est journalisée. Ce journal constitue un actif pour la suite : il rassemble des couples associant ce que le modèle a lu et ce qu'un humain a corrigé, matière première d'un affinage ultérieur du modèle.

4.5 Intégration à OpenCRVS

4.5.1 Le mapping vers la déclaration

Le passage des champs extraits à une déclaration OPENCRVS mobilise plusieurs conversions non triviales :

La table d’alias elle ramène les vocabulaires des vingt-sept packs vers les identifiants du formulaire cible.

La séparation des noms le formulaire attend un prénom et un nom de famille distincts, là où l’acte fournit souvent une chaîne unique. La règle exploite la convention des actes francophones, qui écrivent le nom de famille en majuscules. Cette règle a ses limites, mesurées au chapitre 5.

La normalisation des énumérations le sexe, écrit « Masculin », « M » ou « MASCULIN » selon les actes, est converti vers la valeur attendue.

La conversion des nationalités les adjectifs de nationalité sont convertis en codes pays normalisés. Les cas ambigus ne sont jamais tranchés.

La résolution des lieux lorsque l’acte ne mentionne qu’une ville, le modèle est interrogé pour obtenir la hiérarchie administrative correspondante. Cette résolution n’est retenue qu’au-dessus d’un seuil de confiance, et le résultat est toujours signalé comme « à confirmer ».

Tout ce qui ne peut pas être placé dans un champ structuré — heure de naissance, nom de l’officier, mentions marginales — n’est pas perdu pour autant : ces valeurs sont reportées dans le commentaire de revue, avec leur score. L’officier voit ainsi l’intégralité de ce que le système a lu.

4.5.2 Voie par notification

Cette voie enchaîne quatre appels : obtention d’un jeton, création de l’événement, téléversement du scan, puis envoi de la déclaration accompagnée de sa pièce jointe. La déclaration pré-remplie apparaît dans la file de travail de l’officier.

4.5.3 Voie intégrée au formulaire

Cette voie ajoute au formulaire de déclaration un panneau permettant de déposer un scan sans quitter OPENCRVS. Elle a été réalisée en s’inspirant d’un mécanisme déjà présent dans la plateforme : le lecteur d’identité, qui interroge un service externe et injecte les valeurs obtenues dans le formulaire.

L’ensemble tient dans un fichier de configuration ajouté au dépôt de configuration pays. Aucune ligne du cœur d’OPENCRVS n’a été modifiée, ce qui satisfait le besoin BNF3 et garantit la compatibilité avec les mises à jour de la plateforme.

4.6 Difficultés rencontrées

Cette section rend compte des obstacles réels du projet. Elle figure ici parce que leur résolution constitue une part substantielle du travail d’ingénierie, et parce que les mentionner permet à un lecteur reprenant le sujet d’éviter les mêmes impasses.

Difficulté	Diagnostic	Résolution
Temps de traitement d'environ dix minutes par acte	Un appel au modèle par zone recadrée	Regroupement par lots, parallélisation, limitation du raisonnement interne : environ une minute
Épuisement des quotas d'appel au modèle	Limite journalière de l'offre gratuite	Rotation automatique entre plusieurs clés ; échec explicite plutôt que silencieux
Champs vides malgré une extraction correcte	Le vocabulaire du pack ne correspondait pas aux identifiants attendus	Table d'alias couvrant les vingt-sept packs
Déclaration invisible dans la file de travail	Identifiant de bureau devenu obsolète après réinitialisation de la base	Synchronisation automatique de l'identifiant au démarrage
Impossibilité d'envoyer le fichier au service depuis le formulaire	Le type de champ concerné ne transmet que du texte structuré	Téléversement vers le stockage d'OpenCRVS, puis transmission du seul chemin
Valeurs produites mais champs restant vides	Un champ ne se synchronise que si sa configuration déclare la source comme parente	Déclaration conjointe de la source et de la valeur sur chaque champ concerné
Champs encore vides après cette correction	La réponse exposait des clés contenant des points, illisibles pour le mécanisme de résolution	Ajout d'une représentation réellement imbriquée dans la réponse
Rendu du panneau dégradé et erreurs affichées	Les balises HTML des libellés sont interprétées comme une syntaxe de formatage	Suppression des balises ; remplacement de l'image intégrée par un bouton
Une vingtaine de terminaux ouverts à chaque démarrage	Chaque tâche planifiée ouvrait sa console ; en fermer une arrêta le service	Lancement par un script masquant la fenêtre, sans élévation de privilèges

Tableau 8 — Principales difficultés techniques rencontrées et leur résolution

Trois de ces difficultés méritent un commentaire, car elles illustrent une même leçon : une chaîne d'intégration peut échouer silencieusement à chacun de ses maillons, et seul un diagnostic mené maillon par maillon permet de trouver le bon.

Le cas des champs restant vides malgré un pré-remplissage correct en est l'illustration la plus nette. Trois causes différentes ont produit exactement le même symptôme : d'abord un vocabulaire de champs non concordant, puis une propriété de configuration manquante, enfin un format de réponse incompatible avec le mécanisme de résolution des valeurs. Chaque correction paraissait avoir résolu le problème jusqu'à ce que le symptôme réapparaisse. Ce n'est qu'en examinant le code de la plateforme, plutôt qu'en supposant son fonctionnement, que la cause finale a été identifiée.

4.7 Industrialisation de l'environnement

Une part non négligeable du travail a porté sur la fiabilité de l'environnement de développement. Faire fonctionner simultanément quatorze microservices, six composants d'infrastructure et l'application développée exige un outillage propre.

Un script unique démarre l'ensemble, affiche l'état de chaque service, relance automatiquement ceux qui ne répondent pas, puis vérifie la cohérence de la configuration d'intégration. Les pièges découverts en cours de stage — perte de configuration après un arrêt brutal, identifiants régénérés, processus résiduels après redémarrage — sont détectés et corrigés automatiquement lorsque c'est possible, signalés explicitement sinon.

4.8 Conclusion du chapitre

La réalisation a confirmé la validité de la conception, tout en révélant que la difficulté principale ne résidait pas dans l'extraction elle-même — le modèle lit correctement des documents difficiles — mais dans les points de jonction entre systèmes. Le chapitre suivant mesure la qualité effectivement obtenue.

Évaluation et résultats

Ce chapitre présente la démarche d'évaluation, les résultats obtenus, les erreurs relevées et les limites de la mesure. Il occupe une place importante dans ce rapport pour une raison de fond : un système d'extraction dont on ne sait pas mesurer la qualité ne peut pas être déployé sur un registre juridique.

5.1 Deux questions distinctes

L'évaluation répond à deux questions qu'il serait trompeur de confondre.

La justesse quand le système lit un champ, lit-il la bonne valeur ? Cette question exige des valeurs de référence auxquelles comparer les sorties.

Le rendement sur un lot représentatif, quelle proportion du travail de saisie est effectivement épargnée à l'officier ? Cette question se mesure sans référence, sur l'ensemble des documents traités.

Un système peut être très juste sur les rares champs qu'il ose remplir, tout en n'épargnant presque aucun travail ; il peut inversement remplir beaucoup de champs de façon peu fiable. Seule la lecture conjointe des deux mesures a du sens.

5.2 Protocole d'évaluation de la justesse

5.2.1 Constitution du jeu de référence

Un jeu de référence a été constitué en transcrivant les valeurs attendues directement depuis les actes. Il couvre neuf documents et soixante-neuf champs.

Le choix des documents obéit à un critère explicite : *couvrir le difficile autant que le facile*. Une première version de l'évaluation, portant sur six documents bien lisibles et cinq champs simples, produisait des scores parfaits sur toute la ligne. Ce résultat était une propriété de l'évaluation, non du système : une mesure incapable de constater un échec ne mesure rien. Le jeu a donc été élargi pour inclure une copie dactylographiée à l'encre pâlie, un acte mentionnant l'âge des parents au lieu de leur date de naissance, et un acte narratif dense.

Les champs évalués ont été étendus de la même manière : au-delà de l'identité de l'enfant et du nom des parents, l'évaluation porte désormais sur les dates de naissance des parents, leurs professions et leurs nationalités — champs nettement plus difficiles. Plusieurs de ces champs sont délibérément vides dans la référence, lorsque l'acte ne les mentionne pas : produire une valeur pour ceux-là compte alors comme une hallucination.

5.2.2 Traitement particulier des noms

Les noms font l'objet d'une double mesure, pour une raison méthodologique.

Les actes n'écrivent pas les noms dans le même ordre selon les pays : le nom de famille précède le prénom au Nigéria, au Bénin et au Mali, alors qu'il le suit en Côte d'Ivoire ou en Tunisie. Comparer l'ordre imprimé reviendrait à évaluer une convention typographique plutôt que la qualité de lecture. Le nom est donc comparé indépendamment de l'ordre des mots.

Mais la répartition entre prénom et nom de famille compte réellement, puisque le formulaire cible comporte deux champs distincts. Elle fait donc l’objet d’une mesure séparée.

Cette distinction n’est pas cosmétique : elle a permis de mettre en évidence un défaut systématique qui serait autrement resté confondu avec du bruit.

5.2.3 Métriques retenues

Les métriques sont celles justifiées au chapitre 2 : ANLS comme indicateur principal, taux d’erreur au caractère et au mot, précision, rappel et F1 en correspondance exacte et approchée, taux d’hallucination et conformité au schéma.

5.3 Résultats de justesse

Le Tableau 9 présente les résultats mesurés sur les neuf documents.

Métrique	Valeur	Lecture
ANLS	0,967	Les valeurs lues sont très proches des références attendues
F1 correspondance exacte	0,926	Neuf champs sur dix sont strictement identiques à la référence
F1 correspondance approchée	0,985	Les écarts restants sont, pour l’essentiel, mineurs
Précision (exacte)	0,940	Parmi les valeurs affirmées, la grande majorité est exacte
Rappel (exact)	0,913	La plupart des champs présents dans l’acte sont produits
Taux d’erreur caractère	0,005	Un demi-caractère erroné pour cent caractères lus
Taux d’erreur mot	0,034	Environ trois mots sur cent diffèrent de la référence
Couverture	97,1 %	Presque tous les champs présents dans l’acte reçoivent une valeur
Taux d’hallucination	0 %	Aucune valeur produite pour un champ absent du document
Conformité au schéma	100 %	Toutes les valeurs sont directement exploitables par OpenCRVS
Découpage prénom / nom	81,5 %	Un nom sur cinq est mal réparti entre les deux champs

Tableau 9 — Résultats de justesse sur neuf actes et soixante-neuf champs

Trois observations méritent d’être soulignées.

Le **taux d’hallucination nul** est le résultat le plus significatif au regard de l’objectif du projet. Plusieurs champs de la référence sont volontairement vides — un acte algérien indique l’âge des parents et non leur date de naissance — et le système n’a produit aucune valeur pour ceux-là. Le principe d’honnêteté produit ici un effet mesurable.

La **conformité au schéma de 100 %** signifie qu’aucune valeur produite ne nécessite de retraitement avant injection dans le registre.

Le **découpage prénom / nom à 81,5 %** est le point faible identifié, et il est analysé plus loin.

La Figure 10 détaille la justesse champ par champ.




Figure 10 — Similarité ANLS par champ évalué




Figure 11 — Proportion de champs strictement exacts par document

5.4 Erreurs relevées

L'évaluation relève six champs erronés ou manquants sur soixante-neuf, et cinq inversions entre prénom et nom. Ils sont énumérés au Tableau 10 plutôt que résumés : un rapport d'évaluation qui n'expose pas ses échecs ne permet pas d'apprécier la portée de ses réussites.

Document	Champ	Attendu	Obtenu
Madagascar	Date de naissance	1999-07-08	1989-07-08
Madagascar	Nom du père	Zafindratovo	Zafindrat
Mali	Nom de la mère	FATOUMATA	FATOUKATA
Sierra Leone	Nationalité du père	SLE	non extrait
Sierra Leone	Nationalité de la mère	SLE	non extrait
Côte d'Ivoire	Profession du père	Directeur de la Radiodiffusion de la Côte d'Ivoire	variante de ponctuation

Tableau 10 — Champs erronés ou manquants relevés par l'évaluation

Ces erreurs se répartissent en trois natures, dont la gravité diffère considérablement.

L'erreur de lecture de chiffre sur l'acte malgache, l'année 1999, écrite en toutes lettres au sein d'une phrase continue, a été lue 1989. C'est de loin l'erreur la plus préoccupante : une date reste plausible

même lorsqu'elle est fausse, et rien dans sa forme ne signale le problème. Un officier qui ne relirait pas ce champ l'inscrirait tel quel dans le registre. Cette erreur unique justifie à elle seule le maintien d'une vérification humaine.

Les erreurs de caractère sur la copie malienne dactylographiée à l'encre pâlie, un prénom a été lu FATOUKATA au lieu de FATOUMATA, et un prénom malgache a été tronqué. Ces erreurs sont visibles : un officier les repère immédiatement en regardant le document. Leur coût est faible.

Les valeurs non extraites les nationalités sierra-léonaises n'ont pas été produites, non par échec de lecture, mais parce que le pack pays correspondant ne comportait pas de champ pour les recevoir. Ce n'est pas une limite du modèle mais une lacune de configuration, corrigée pour un pays et à étendre aux autres.

5.4.1 Le défaut systématique : l'ordre des noms

Les cinq inversions relevées ne sont pas dispersées au hasard : elles se concentrent sur les actes béninois et maliens, c'est-à-dire ceux qui écrivent le nom de famille avant le prénom et intégralement en majuscules.

La cause est identifiée. La règle de séparation s'appuie sur la casse : dans les actes francophones, le nom de famille est habituellement en majuscules et le prénom en minuscules. Lorsque l'ensemble du nom est en majuscules, ce signal disparaît, et la règle retombe sur une convention par défaut — le dernier mot est le nom de famille — qui se trouve être fausse pour ces pays.

Deux correctifs sont envisageables. Le premier consiste à exploiter le nom de famille de l'enfant, souvent connu par un champ explicitement étiqueté, lorsque ce même mot apparaît dans le nom d'un parent : les familles partagent leur patronyme. Le second consiste à déclarer l'ordre des noms dans la configuration du pays, cette convention étant nationale et stable.

Ce défaut est signalé plutôt que corrigé dans l'urgence. Le corriger sans disposer d'un jeu de validation plus large ferait courir un risque de régression sur les autres pays, dont le comportement actuel est correct. La démarche d'évaluation aurait perdu son sens si elle avait servi à justifier une correction non validée.

5.5 Rendement sur le lot d'échantillons

La seconde question — combien de saisie est effectivement épargnée — se mesure sans référence, sur un lot plus large.

Indicateur	Valeur
Documents évalués (actes tapés)	21
Champs détectés par document, en moyenne	environ 23
Champs auto-acceptés, en moyenne	environ 57 %
Champs OpenCRVS pré-remplis par document, en moyenne	environ 7
Temps de traitement par document	40 à 90 secondes

Tableau 11 — Rendement mesuré sur le lot d'échantillons

La Figure 12 présente la répartition des scores de confiance sur ce lot.

Répartition des scores de confiance




Figure 12 — Répartition des champs par bande de confiance

Un champ « auto-accepté » est un champ dont la confiance dépasse le seuil et qui ne fait donc l'objet d'aucun signalement. Les champs situés sous le seuil sont néanmoins pré-remplis, mais explicitement marqués « à vérifier ». Cette distinction est au cœur du dispositif : elle indique à l'officier où porter son attention, au lieu de le contraindre à tout relire.

5.6 Limites de la démarche

Trois réserves doivent accompagner ces chiffres. Les taire donnerait une apparence de solidité que la mesure ne possède pas encore.

La taille de l'échantillon neuf documents et soixante-neuf champs constituent un jeu modeste. Les intervalles de confiance associés à des proportions calculées sur un tel effectif sont larges, et un document supplémentaire particulièrement difficile déplacerait sensiblement les résultats.

L'origine des références les valeurs de référence ont été transcrites dans le cadre de ce projet, et non produites par un annotateur indépendant. Une erreur de lecture commise à la fois par le système et par la transcription resterait invisible. C'est la limite méthodologique la plus sérieuse.

Le périmètre les actes manuscrits sont exclus de ces mesures. La reconnaissance d'écriture manuscrite constitue un problème distinct et nettement plus difficile ; les inclure aurait masqué la performance réelle sur la cible du projet, mais leur exclusion signifie que les chiffres ne s'appliquent pas à eux.

Ce que ces résultats établissent, et ce qu'ils n'établissent pas

Ils établissent que le système traite correctement les documents évalués, que ses sorties sont directement exploitables par le registre cible, et qu'il n'invente pas de valeurs. Ils n'établissent pas une absence d'erreurs en général. La levée de la principale réserve passe par la vérification d'une partie des références par un officier d'état civil, ce qui romprait la dépendance entre le système mesuré et la mesure.

5.7 Reproductibilité

L'ensemble des chiffres présentés est recalculable. Les valeurs de référence sont versionnées avec leur provenance, les métriques sont produites par deux programmes exécutables en une commande, et le rapport d'évaluation détaillé est généré à partir de leurs sorties, sans aucune valeur saisie manuellement. Une modification du système suivie d'une nouvelle exécution suffit à obtenir des chiffres à jour.

5.8 Conclusion du chapitre

Le système atteint une justesse élevée sur les documents évalués, ne produit aucune valeur inventée, et fournit des sorties directement exploitables. Il présente un défaut systématique identifié et documenté sur l'ordre des noms dans certaines conventions nationales, et une erreur de lecture de date qui rappelle pourquoi la vérification humaine demeure nécessaire. La mesure elle-même comporte des limites qui sont énoncées plutôt que masquées.

Conclusion générale

Bilan du travail réalisé

Ce stage est parti d'un constat simple : la numérisation des actes d'état civil africains bute moins sur la photographie des registres que sur la ressaisie de leur contenu. Le travail a consisté à transformer cette ressaisie en vérification.

Le système réalisé lit un acte de naissance scanné, en extrait les champs à l'aide d'un modèle vision-langage, les valide, leur associe un score de confiance, puis pré-remplit une déclaration dans le registre civil numérique OPENCRVS. Il couvre vingt-sept pays, traite un document en quarante à quatre-vingt-dix secondes, et propose deux voies d'intégration répondant à deux usages distincts : le traitement par lots d'un fonds d'archives, et le traitement à l'unité au guichet, sans quitter le formulaire.

Les objectifs fixés en début de stage sont atteints. L'extensibilité à de nouveaux pays se fait par configuration et non par code. Chaque valeur porte un score exploitable. L'intégration ne modifie aucune ligne du cœur d'OPENCRVS, ce qui préserve la compatibilité avec ses mises à jour. Une interface de vérification humaine existe, et les corrections y sont capitalisées.

Ce que la démarche a apporté

Au-delà du logiciel, trois enseignements se dégagent.

Le premier concerne le **choix technologique**. Les modèles vision-langage se sont montrés remarquablement robustes à l'hétérogénéité documentaire : ils lisent un acte narratif malgache et un formulaire à cases malien sans adaptation, là où une approche par gabarit aurait exigé un développement par mise en page. Leur contrepartie, la capacité à produire une valeur plausible mais fausse, s'est révélée maîtrisable à condition d'en faire une contrainte de conception explicite plutôt qu'un risque résiduel.

Le deuxième concerne la **nature réelle de la difficulté**. Le travail le plus long n'a pas porté sur l'extraction elle-même, qui a fonctionné assez tôt, mais sur les points de jonction entre systèmes : formats de réponse, mécanismes de propagation des valeurs, contraintes non documentées de la plateforme cible. Un symptôme unique, des champs restant vides, a recouvert successivement trois causes distinctes, et seule l'inspection du code de la plateforme, plutôt que la supposition de son fonctionnement, a permis d'aboutir.

Le troisième concerne l'**évaluation**. Une première campagne, portant sur des documents faciles et des champs simples, produisait des scores parfaits. Élargir délibérément la mesure aux cas difficiles a fait apparaître des défauts réels, dont un défaut systématique lié aux conventions d'écriture des noms. Une évaluation incapable de constater un échec ne mesure rien : c'est probablement l'enseignement méthodologique le plus durable de ce stage.

Limites

Le système présente des limites qu'il convient de rappeler. Le découpage entre prénom et nom de famille est erroné pour les conventions écrivant le patronyme en premier et en majuscules. Les actes manuscrits, bien que traités, ne sont pas couverts par les mesures de qualité. L'évaluation repose sur un échantillon modeste dont les références n'ont pas été validées par un tiers indépendant. Enfin, le recours à un modèle distant n'est pas acceptable en production pour des données d'état civil, même si la bascule vers un modèle hébergé localement est prévue par l'architecture.

Perspectives

Plusieurs prolongements se dégagent naturellement.

À **court terme**, la correction du défaut d'ordre des noms, l'ajout des champs de nationalité aux packs pays qui en sont dépourvus, et surtout l'élargissement du jeu de référence avec une validation par un officier d'état civil, qui lèverait la principale réserve méthodologique.

À **moyen terme**, la bascule vers un modèle hébergé localement, condition de tout déploiement réel ; l'idempotence des envois, afin qu'un document retransmis ne crée pas de doublon ; et la couverture de la reconnaissance manuscrite, qui constitue à elle seule un sujet d'étude.

À **long terme**, le journal des corrections humaines accumulé par l'application ouvre la voie à un affinage du modèle sur ce domaine documentaire précis. Chaque correction effectuée par un officier constitue un exemple d'entraînement : le système peut ainsi s'améliorer par son usage même, ce qui est probablement la perspective la plus intéressante de ce travail.

Apport personnel

Ce stage m'a permis de conduire un projet de bout en bout, depuis l'analyse d'un besoin métier jusqu'à l'intégration dans une plateforme existante, en passant par la conception, la réalisation et l'évaluation. Il m'a surtout appris qu'un système destiné à un usage administratif sensible se juge autant à la manière dont il gère son incertitude qu'à ses performances nominales, et qu'une mesure honnête de ses limites vaut mieux qu'un chiffre flatteur.

Bibliographie et webographie

Extraction et compréhension de documents

- [1] M. Mathew, D. Karatzas, C. V. Jawahar, *DocVQA: A Dataset for VQA on Document Images*, IEEE Winter Conference on Applications of Computer Vision, [2021] Référentiel qui a établi l'ANLS comme métrique principale de l'extraction documentaire.
- [2] Z. Huang et al., *ICDAR 2019 Competition on Scanned Receipt OCR and Information Extraction (SROIE)*, International Conference on Document Analysis and Recognition, 2019. Référence pour l'évaluation par champ.
- [3] Y. Xu et al., *LayoutLM: Pre-training of Text and Layout for Document Image Understanding*, ACM SIGKDD, 2020. Approche spécialisée écartée ici faute de corpus annoté disponible.
- [4] G. Kim et al., *OCR-free Document Understanding Transformer (Donut)*, European Conference on Computer Vision, 2022.
- [5] R. Smith, *An Overview of the Tesseract OCR Engine*, International Conference on Document Analysis and Recognition, 2007.

Métriques d'évaluation

- [1] K. Papineni et al., *BLEU: a Method for Automatic Evaluation of Machine Translation*, Association for Computational Linguistics, 2002.
- [2] C.-Y. Lin, *ROUGE: A Package for Automatic Evaluation of Summaries*, Workshop on Text Summarization, 2004.
- [3] V. I. Levenshtein, *Binary codes capable of correcting deletions, insertions and reversals*, Soviet Physics Doklady, 1966.

État civil et identité légale

- [1] Nations unies, *Objectifs de Développement Durable, cible 16.9 : garantir à tous une identité juridique, notamment grâce à l'enregistrement des naissances*.
- [2] Nations unies, Département des affaires économiques et sociales, *Principes et recommandations pour un système de statistiques de l'état civil*.
- [3] OpenCRVS, *Documentation technique et guide d'intégration*, <https://documentation.opencrvs.org>.
- [4] MOSIP, *Modular Open Source Identity Platform, documentation*, <https://docs.mosip.io>.

Annexes

Annexe A — Structure du rapport d'extraction

Chaque document traité produit un rapport structuré. L'extrait ci-dessous illustre la description d'un champ, volontairement riche afin que toute valeur puisse être expliquée et non seulement affichée.

```
{
  "doc_id": "tn_extrait_1981",
  "status": "needs_review",
  "fields_total": 25,
  "fields_auto_accepted": 18,
  "localization": {
    "country": "tn",
    "template": "tn_extrait_fr_v1",
    "locator": "template",
    "anchors_found": 20,
    "anchors_interpolated": 4
  },
  "fields": {
    "date_naissance": {
      "value": "1981-03-10",
      "raw": "dix mars mil neuf cent quatre-vingt-un",
      "type": "date",
      "page_value": "1981-03-10",
      "crop_value": "1981-03-10",
      "agreement": true,
      "model_confidence": 0.95,
      "score": 0.95,
      "band": "high",
      "needs_review": false,
      "bbox": [412, 688, 1120, 742]
    }
  }
}
```

La présence conjointe de la valeur lue par la passe page et par la passe recadrage, ainsi que de leur accord, permet de retracer l'origine du score de confiance.

Annexe B — Commandes principales

Commande	Effet
run_pipeline.py <scan> --backend gemini	Traite un acte et produit son rapport structuré
uvicorn review.app:app --port 8000	Démarre l'application web de dépôt et de correction
tools/send_to_opencrvs.py runs/<doc>	Envoie une déclaration pré-remplie vers OpenCRVS
tools/evaluate_quality.py	Recalcule les métriques de justesse contre le jeu de référence
tools/evaluate_batch.py	Recalcule les métriques de rendement sur le lot d'échantillons
tools/build_eval_report.py	Régénère le rapport d'évaluation détaillé
start-opencrvs.ps1	Démarre la plateforme complète et vérifie son état

Annexe C — Pays couverts

Vingt-sept packs pays sont disponibles, complétés par un pack générique utilisé lorsque l'origine du document n'est pas reconnue :

Afrique du Sud, Algérie, Angola, Bénin, Cameroun, Cap-Vert, Congo-Brazzaville, Côte d'Ivoire, Égypte, Gabon, Guinée, Kenya, Liban, Libéria, Madagascar, Mali, Maroc, Maurice, Mauritanie, Nigéria, République démocratique du Congo, Rwanda, Sénégal, Seychelles, Sierra Leone, Togo, Tunisie.

Annexe D — Éléments à compléter avant remise

Les informations suivantes relèvent de l'organisme d'accueil et des personnes ayant encadré ce stage. Elles n'ont volontairement pas été renseignées, un rapport signé ne pouvant contenir d'affirmations invérifiables à leur sujet.

Emplacement	Information attendue
Page de garde	Nom de l'organisme, encadrant entreprise, encadrant académique
Remerciements	Noms de l'encadrant entreprise, de l'encadrant académique et de l'équipe
Chapitre 1, présentation de l'organisme	Activité, effectifs, implantation, positionnement
Chapitre 1, organigramme	Département, nom de l'encadrant, équipes voisines
Figure de l'organigramme	Régénérer après mise à jour des libellés du script de figures