

Évaluation du pipeline d'extraction

OCR d'actes d'état civil africains → pré-remplissage OpenCRVS
Métriques mesurées, méthode et limites

1. Ce qui est mesuré, et pourquoi

Deux questions distinctes sont évaluées séparément, car elles ne se confondent pas. **La justesse** : quand le système lit un champ, lit-il la bonne valeur ? Elle se mesure contre des valeurs de référence transcrites depuis les actes. **Le rendement** : sur un lot représentatif, quelle part du travail de saisie est effectivement épargnée à l'officier ? Elle se mesure sans référence, sur l'ensemble des documents traités.

Le choix des métriques suit l'usage du domaine (DocVQA, SROIE, CORD, OmniDocBench) plutôt que les métriques de génération de texte. ANLS et CER tolèrent une coquille tout en sanctionnant une valeur fausse ; la précision et le rappel par champ traitent l'extraction comme une tâche de recherche d'information. BLEU et ROUGE ne figurent qu'en annexe, sur le seul champ en texte libre : le recouvrement de n-grammes récompense une paraphrase fluide et reste aveugle à une date fausse — or c'est précisément l'erreur qui compte pour un registre d'état civil.

2. Justesse de l'extraction

Mesurée sur **6 actes tapés/imprimés** (30 champs de référence), un par pays.

Métrique	Valeur	Ce qu'elle dit
ANLS	1.000	Similarité de Levenshtein normalisée, seuil 0,5 (convention DocVQA)
Exact match F1	1.000	Valeur strictement identique à la référence
Fuzzy match F1	1.000	Tolérance d'une variation mineure (similarité $\geq 0,8$)
CER	0.000	Taux d'erreur caractère sur les champs renseignés
WER	0.000	Taux d'erreur mot
Couverture	100.0 %	Champs présents dans l'acte que le système a effectivement produits
Hallucinations	0.0 %	Valeurs inventées pour un champ absent de l'acte
Conformité schéma	100.0 %	Valeurs directement exploitables par OpenCRVS (date ISO, énumération sexe...)
Split prénom / nom	88.9 %	Chaque moitié du nom placée dans le bon champ

Limites de ce chiffre — à lire avant de le citer. L'échantillon est petit (6 documents, 30 champs) et, surtout, les valeurs de référence ont été transcrites dans le cadre de ce projet, et non produites par un annotateur humain indépendant. Une erreur de lecture commise à la fois par le pipeline et par la transcription ne serait donc pas détectée. Ces résultats démontrent que le système traite correctement ces documents-là ; ils ne prouvent pas une absence d'erreurs en général. Une validation par un officier d'état civil sur un lot plus large est la prochaine étape nécessaire.

2.1 Détail par champ

Champ	n	Exact	ANLS	CER	Couverture
Nom de l'enfant	6	6/6	1.00	0.00	100.0 %

Champ	n	Exact	ANLS	CER	Couverture
Date de naissance	6	6/6	1.00	0.00	100.0 %
Sexe	6	6/6	1.00	0.00	100.0 %
Nom du père	6	6/6	1.00	0.00	100.0 %
Nom de la mère	6	6/6	1.00	0.00	100.0 %

2.2 Détail par document

Document	Pays	Champs exacts	ANLS
tn_extrait_1981	TN	5/5	1.00
test_coteivoire	CI	5/5	1.00
bj_volet_2018	BJ	5/5	1.00
sl_acte_1974	SL	5/5	1.00
ng_certificat_1978	NG	5/5	1.00
mr_extrait_1987	MR	5/5	1.00

3. Défaut identifié par l'évaluation

L'évaluation a mis en évidence un défaut réel, invisible sur les chiffres agrégés de justesse : **l'ordre prénom / nom est inversé pour les parents lorsque l'acte écrit le nom de famille en premier et tout en majuscules** (cas du Bénin : « SANNI GOUDA », où SANNI est le nom de famille). L'heuristique repose sur la casse — les majuscules signalent le nom de famille dans les actes francophones — et ne peut pas trancher quand tout est en majuscules ; elle retombe alors sur « le dernier mot est le nom de famille », ce qui est faux pour ces conventions.

Le nom lui-même est correctement lu : c'est sa répartition entre les deux champs d'OpenCRVS qui est erronée. Deux correctifs sont envisageables : exploiter le nom de famille de l'enfant, connu par un champ étiqueté, lorsqu'il apparaît aussi dans le nom d'un parent (familles partageant le patronyme) ; et déclarer l'ordre des noms dans le pack pays, l'information étant une convention nationale stable. Ce défaut est signalé plutôt que corrigé dans l'urgence : le corriger sans jeu de validation plus large risquerait d'introduire des régressions sur les autres pays.

4. Rendement sur le lot d'échantillons

Mesuré sans référence sur **21 actes tapés/imprimés** (un par pays), ce volet répond à la question opérationnelle : combien de saisie le système épargne-t-il réellement ?

Indicateur	Valeur
Documents évalués	21
Champs détectés par document (moyenne)	22.9
Champs auto-acceptés (moyenne)	56.5 %
Champs OpenCRVS pré-remplis par document (moyenne)	7.0
Temps de traitement par document	≈ 40 à 90 s

« Auto-accepté » désigne un champ dont la confiance dépasse le seuil de 0,6 et qui ne requiert donc pas de relecture signalée. En dessous du seuil, la valeur est tout de même pré-remplie mais explicitement marquée « à vérifier » : le système préfère signaler un doute plutôt que présenter une valeur incertaine comme sûre.

5. Annexe — métriques de génération (BLEU / ROUGE)

Calculées uniquement sur le lieu de naissance, seul champ en texte libre, et fournies pour comparabilité avec la littérature. Elles ne sont pas retenues comme indicateur principal : un modèle peut obtenir un bon score de recouvrement de n-grammes tout en produisant une date ou un nom faux.

Métrique	Valeur
ANLS (lieu de naissance)	0.667
CER (lieu de naissance)	0.266
ROUGE-L	0.722
BLEU	0.417

L'écart entre ANLS et BLEU sur ce champ illustre le propos : les réponses sont sémantiquement justes (« Abidjan » pour « Clinique du Belvédère à Abidjan ») mais lexicalement plus courtes que la référence, ce que BLEU pénalise lourdement alors que la valeur reste exploitable par l'officier.

6. Méthode et reproductibilité

Les valeurs de référence sont versionnées dans `eval/ground_truth.json`, avec pour chaque champ sa provenance et sa définition. Les métriques sont recalculées par `tools/evaluate_quality.py` (justesse) et `tools/evaluate_batch.py` (rendement) ; ce rapport est produit par `tools/build_eval_report.py` à partir de leurs sorties, sans aucune valeur saisie manuellement. Les actes manuscrits sont exclus de ces chiffres et traités comme un problème distinct : la reconnaissance d'écriture manuscrite est nettement plus difficile, et les mélanger masquerait la performance réelle sur la cible du projet.

Champs évalués : `child.name`, `child.dob`, `child.gender`, `father.name`, `mother.name`. Seuil ANLS : 0.5. Seuil de correspondance approchée : 0.8. Provenance des références : Transcribed by reading each scan in samples/ directly. This is annotation, not an independent gold standard produced by a third party — it is stated plainly wherever the numbers are reported.